

Data oddania: \_\_\_\_\_

Ocena: \_\_\_\_\_

Stanisław Zakrzewski 210360

Maciej Socha 210321

Zadanie 1: Ekstrakcja cech, miary  
podobieństwa, klasyfikacja

## 1. Cel

Celem zadania było poznanie oraz zaimplementowanie różnych metod ekstrakcji cech z tekstów, określania podobieństwa oraz klasyfikacji tekstów.

## 2. Wprowadzenie

Celem projektu jest stworzenie programu pozwalającego na klasyfikację wybranego zbioru elementów. Klasyfikatorem wybranym do tego celu jest metoda k-najbliższych sąsiadów.

Algorytm k najbliższych sąsiadów, nazywamy też potocznie algorytmem knn, pozwala na klasyfikację zbioru wieloelementowego według określonych etykiet. Na początku działania algorytmu k najbliższych sąsiadów określone są wektory dla każdego z elementów podlegających klasyfikacji. W naszym przypadku określanie wektorów polega na odpowiednim przetworzeniu tekstu zawierającego się w elementach zbioru do klasyfikacji. Następnie wektory są umieszczane na przestrzeni n elementowej, gdzie n stanowi liczebność elementów w wektorze. Odślaniane są etykiety, domyślnie 10% dla każdej z etykiet. Odślonięcie etykiet stanowi jeden ze sposobów rozwiązania problemu zimnego startu. Następnie kolejne etykiety są nadawane kolejnym elementom, poprzez znalezienie k najbliższych elementów i wybranie spośród etykiet należących do danych elementów tych, które są najliczniejsze, w przypadku identycznej liczebności etykiet wybierana jest ta, której średnia odległość do aktualnie klasyfikowanego elementu jest mniejsza.

Do wytworzenia wektora cech stosowane są dwa warianty ekstrakcji cech typu Dictionary Matching (DM). W obu przypadkach teksty znajdujące się w artykułach są początkowo poddane procesowi lematyzacji. Proces lematyzacji jest to czynność mająca na celu znalezienia lemmy dla danego słowa, lemma jest to forma podstawowa wyrazu w obszarze części mowy, którą reprezentuje. Następnie następuje proces przyznawania punktów dla poszczególnych słów. Wybierane zostają słowa mające najwięcej punktów. Pierwszy z na początku usuwa wszystkie słowa znajdujące się na przygotowanej wcześniej stop-liście, usuwa wartości liczbowe oraz zwiększa punktację słów znajdujących się bliżej początku tekstu. Drugi sposób bazuje natomiast na algorytmie TFIDF oraz również usuwane są wszelkie wartości liczbowe.

Algorytm TFIDF jest jedną z metod obliczania wagi słów w oparciu o liczbę ich wystąpień. Jest on stosowany między innymi w wyszukiwarkach internetowych. Jest on obliczany przy pomocy wzoru:

$$(tf - idf)_{i,j} = tf_{i,j} \times idf_i$$

gdzie  $tf_{i,j}$  to tak zwany „term frequency” opisany wzorem:

$$tf_{i,j} = \log \frac{n_{i,j}}{\sum_k n_{k,j}}$$

gdzie:  $n_{i,j}$  jest liczbą wystąpień termu ( $t_i$ ) w dokumencie  $d_j$ , a mianownik jest sumą liczby wystąpień wszystkich termów w dokumencie  $d_j \cdot idf_i$  to „inverse document frequency” wyraża się wzorem:

$$idf_i = \log \frac{|D|}{|\{d : t_i \in d\}|}$$

gdzie:  $|D|$  - liczba dokumentów w korpusie  $|\{d : t_i \in d\}|$  - liczba dokumentów zawierających przynajmniej jedno wystąpienie danego termu.

Powstałe w wyniku działania obu ekstraktorów cech wektory są używane do wytworzenia wektorów liczbowych pozwalających na umieszczenie elementów w przestrzeni liczbowej, co jest wymagane w algorytmie k najbliższych sąsiadów.

Obliczenia odległości dokonano w trzech metrykach.

Pierwszą z nich jest metryka Euklidesa, odległość  $d$  obliczana jest przy pomocy wzoru:

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$

Drugą z nich jest metryka Manhattana, nazywana również metryką uliczną, taksówkarską lub miejską. Odległość jest obliczana przy pomocy wzoru:

$$d(x, y) = \sum |x_i - y_i|$$

Trzecią i zarazem ostatnią jest metryka Czebyszewa, odległość jest obliczana przy pomocy wzoru:

$$d(x, y) = \frac{\sum |x_i \cdot y_i|}{\sqrt{\sum x_i^2 \cdot \sum y_i^2}}$$

### 3. Opis implementacji

Algorytmy zostały zaimplementowane w języku Java w wersji 11. Dodatkowo na potrzeby procesu lematyzacji wykorzystano, udostępnioną przez Stanford Natural Language Processing Group, bibliotekę CoreNLP w wersji 3.9.2. Biblioteka ta jest udostępniona z licencją GNU General Public License v3 co pozwala nam korzystać z niej w naszym programie. Biblioteka ta jest bardzo obszerna, w naszym programie wykorzystujemy jedynie funkcjonalność lematyzacji. Jest ona zaimplementowana w klasie StanfordLemmatizer. Implementacja tej klasy została bezpośrednio zaczerpnięta z dokumentacji[5]. Poniżej przedstawiono uproszczony diagram klas. Zaznaczone zostały na nim kluczowe dla działania naszego programu klasy.

Klasa Article odpowiada za przechowywanie informacji niezbędnych do działania programu. Wykorzystujemy ją zarówno do przetwarzania artykułów zawartych w zbiorze danych reuters jak i zestawu artykułów przygotowanego przez nas samych.

Interfejs Extractor służy i znajdująca się w nim metoda extract jest wykorzystywana przy procesie ekstrakcji cech. Implementują ją liczne klasy zawierające się w dwóch sposobach ekstrakcji cech zawartych w programie.



- `folderPath` - ścieżka do folderu z plikami z danymi
- `articlesToReadCount` - liczba plików z artykułami, które program ma wczytać
- `k` -
- `fractionOfUncoveredForEachTag` -
- `tags` - etykiety, według których program ma klasyfikować
- `numberOfElementsPerTag` - liczba elementów jakie ma zawierać w sobie cecha dla każdej z etykiet
- `trainToTestRatio` - stosunek zbioru treningowego do testowego
- `distanceKNN` - metryka pomiaru dystansu w przestrzeni dla algorytmu knn
- `wordSimilarity` - metryka podobieństwa słów
- `extractors` - zestaw ekstraktorów

## 4. Materiały i metody

Klasyfikacja tekstów Reutersa oraz danych zebranych przez nas została wykonana dla obu sposobów ekstrakcji cech i dla każdej z 3 metryk obliczania dystansu w algorytmie k najbliższych sąsiadów. Dla parametru `k` wybrano niektóre wartości ze zbioru (3, 5, 8, 13, 21), tak aby jak najlepiej ukazać właściwości każdego z sposobów ekstrakcji oraz najlepiej dopasować je do zbioru danych testowych. Klasyfikacja na zbiorze Reutersa według tagu PLACES została przeprowadzona dla sześciu etykiet (west-germany, usa, uk, canada, france, japan), przy stosunku zbioru treningowego do testowego 60-40 i dla 10% odkrytych etykiet,

### DODANIE OPISU DRUGIEGO TAGA

natomiast w naszych tekstach klasyfikacja nastąpiła według tagu REVIEWS dla dwóch etykiet (movie, restaurant), równego podziału zbioru elementów na część treningową i testową oraz 20% odkrytych etykiet.

## 5. Wyniki

Wyniki kolejnych przeprowadzanych eksperymentów zostały umieszczone w tabelach poniżej. Początkowa konfiguracja programu znajduje się poniżej, przy kolejnych eksperymentach zostały wspomniane tylko te parametry które były zmieniane.

- `tagClass` = PLACES
- `articlesToReadCount` = 23
- `k` = 3
- `fractionOfUncoveredForEachTag` = 0.1
- `tags` = west-germany, usa, france, uk, canada, japan
- `numberOfElementsPerTag` = 5
- `trainToTestRatio` = 0.6
- `distanceKNN` = euclidean
- `wordSimilarity` = NGrams
- `extractors` = 1

Poniżej znajdują się wyniki dla przedstawionych powyższej parametrów.

Label	Precision	Recall
west-germany	0.39534885	0.3923077
usa	0.83159405	0.9416126
france	0.5064935	0.35779816
uk	0.62025315	0.24873096
canada	0.49079755	0.23738873
japan	0.5652174	0.23636363

Tablica 1: Precision i Recall dla parametrów bazowych

Multi-Class Pecision: 0.7962223

	west-germany	usa	france	uk	canada	japan
west-germany	51	74	0	2	3	0
usa	57	4064	31	57	71	36
france	1	65	39	0	2	2
uk	10	273	5	98	7	1
canada	5	248	2	1	80	1
japan	5	163	0	0	0	52

Tablica 2: Przypisanie tagów dla parametrów bazowych

### 5.1. Eksperymento 1 - Różne metryki odległości

Metryka euklidesowa

Label	Precision	Recall
west-germany	0.39534885	0.3923077
usa	0.83159405	0.9416126
france	0.5064935	0.35779816
uk	0.62025315	0.24873096
canada	0.49079755	0.23738873
japan	0.5652174	0.23636363

Tablica 3: Precision i Recall dla metryki euklidesowej

Multi-Class Pecision: 0.7962223

Metryka uliczna

Label	Precision	Recall
west-germany	0.5566038	0.4402985
usa	0.8411453	0.914457
france	0.32407406	0.2651515
uk	0.45026177	0.22994652
canada	0.45614034	0.31610942
japan	0.53797466	0.425

Tablica 4: Precision i Recall dla metryki ulicznej

Multi-Class Pecision: 0.78732294  
Metryka Czebyszewa

Label	Precision	Recall
west-germany	0.64788735	0.35384616
usa	0.8515893	0.91464823
france	0.37195122	0.5126051
uk	0.4652778	0.17539267
canada	0.52517986	0.43843845
japan	0.49222797	0.4589372

Tablica 5: Precision i Recall dla metryki Czebyszewa

Multi-Class Pecision: 0.7954958

## 5.2. Eksperymento 2 - różne metryki porównywania słów

NGramy,  $n = 3$

Label	Precision	Recall
west-germany	0.39534885	0.3923077
usa	0.83159405	0.9416126
france	0.5064935	0.35779816
uk	0.62025315	0.24873096
canada	0.49079755	0.23738873
japan	0.5652174	0.23636363

Tablica 6: Precision i Recall dla NGramów,  $n = 3$

Multi-Class Pecision: 0.7962223  
NGramy,  $n = 2$

Label	Precision	Recall
west-germany	0.5416667	0.104
usa	0.80586374	0.94232106
france	0.22972973	0.16037735
uk	0.26666668	0.12276215
canada	0.4347826	0.16574585
japan	0.47619048	0.09756097

Tablica 7: Precision i Recall dla NGramów,  $n = 2$

Multi-Class Pecision: 0.7675263  
NGramy,  $n = 4$

Label	Precision	Recall
west-germany	0.5652174	0.36879432
usa	0.847703	0.9302486
france	0.36619717	0.23853211
uk	0.41411042	0.34526855
canada	0.6785714	0.23312883
japan	0.6884058	0.4871795

Tablica 8: Precision i Recall dla NGramów,  $n = 4$

Multi-Class Pecision: 0.80366874

Uogólnione NGramy

Label	Precision	Recall
west-germany	0.7589286	0.65891474
usa	0.8819797	0.9648311
france	0.46666667	0.7241379
uk	0.7490196	0.49354005
canada	1.0	0.099415205
japan	0.76649743	0.7190476

Tablica 9: Precision i Recall dla UogólnionychNGramów

Multi-Class Pecision: 0.85633856

### 5.3. Eksperymento 3 - Różne wartości parametru $k$

$k = 3$

Label	Precision	Recall
west-germany	0.39534885	0.3923077
usa	0.83159405	0.9416126
france	0.5064935	0.35779816
uk	0.62025315	0.24873096
canada	0.49079755	0.23738873
japan	0.5652174	0.23636363

Tablica 10: Precision i Recall dla  $k = 3$

Multi-Class Pecision: 0.7962223

$k = 5$

Label	Precision	Recall
west-germany	0.59	0.43382353
usa	0.83722854	0.93855786
france	0.46666667	0.26168224
uk	0.46025103	0.28795812
canada	0.6566265	0.29945055
japan	0.5660377	0.29411766

Tablica 11: Precision i Recall dla  $k = 5$



Multi-Class Precision: 0.8016709

k = 8

Label	Precision	Recall
west-germany	1.0	0.09375
usa	0.8347242	0.95040554
france	0.44827586	0.10655738
uk	0.6	0.29210526
canada	0.625	0.375
japan	0.58278143	0.43781096

Tablica 12: Precision i Recall dla k = 8

Multi-Class Precision: 0.81002545

k = 13

Label	Precision	Recall
west-germany	0.61290324	0.2753623
usa	0.8147582	0.98611754
france	1.0	0.094339624
uk	1.0	0.09793814
canada	0.67832166	0.297546
japan	1.0	1.0

Tablica 13: Precision i Recall dla k = 13

Multi-Class Precision: 0.81129676

k = 21

Label	Precision	Recall
west-germany	1.0	0.09375
usa	0.81465435	0.9944815
france	1.0	0.09615385
uk	1.0	0.104
canada	0.7826087	0.26548672
japan	1.0	0.09952607

Tablica 14: Precision i Recall dla k = 21

Multi-Class Precision: 0.81674534

#### 5.4. Eksperymento 4 - Różne ekstraktory

Ekstraktor nr 1

Label	Precision	Recall
west-germany	0.39534885	0.3923077
usa	0.83159405	0.9416126
france	0.5064935	0.35779816
uk	0.62025315	0.24873096
canada	0.49079755	0.23738873
japan	0.5652174	0.23636363

Tablica 15: Precision i Recall dla ekstraktora 1.

Multi-Class Pecision: 0.7962223

Ekstraktor nr 2 articlesToReadCount = 10

Label	Precision	Recall
west-germany	0.17948718	0.13461539
usa	0.81395346	0.94287044
france	0.6363636	0.1
uk	0.30555555	0.17837837
canada	0.6060606	0.104166664
japan	0.19444445	0.10144927

Tablica 16: Precision i Recall dla ekstraktora 2.

Multi-Class Pecision: 0.77324516

### 5.5. Eksperymento 5 - Inny tag

Eksperymenty dla tagu TOPICS oraz etykiet coffe, gold. Pozostałe parametry standardowe.

Label	Precision	Recall
coffee	0.9811321	0.9122807
gold	0.9074074	0.98

Tablica 17: Precision i Recall dla tagu TOPISC

Multi-Class Pecision: 0.94392526

distanceKNN = manhattan

Label	Precision	Recall
coffee	0.94827586	0.94827586
gold	0.93877554	0.93877554

Tablica 18: Precision i Recall dla tagu TOPISC i dystansu miejskiego

Multi-Class Pecision: 0.94392526

distanceKNN = chebyshev

Label	Precision	Recall
coffee	0.98245615	0.9655172
gold	0.96	0.97959185

Tablica 19: Precision i Recall dla tagu TOPISC i dystansu Czebyszewa

Multi-Class Pecision: 0.97196263  
extractors = 2

Label	Precision	Recall
coffee	0.6213592	1.0
gold	1.0	0.093023255

Tablica 20: Precision i Recall dla tagu TOPISC i 2. ekstraktora

Multi-Class Pecision: 0.635514  
trainToTestRatio = 0.3f

Label	Precision	Recall
coffee	0.975	0.975
gold	0.9714286	0.9714286

Tablica 21: Precision i Recall dla tagu TOPISC i stosunku zbiorów 0.3

Multi-Class Pecision: 0.97333336  
k = 5

Label	Precision	Recall
coffee	0.91935486	1.0
gold	1.0	0.9

Tablica 22: Precision i Recall dla tagu TOPISC i k = 5

Multi-Class Pecision: 0.95327103

## 5.6. Eksperymento 6 - Nasz zbiór tekstów

Standardowe parametry

Label	Precision	Recall
movie	0.5641026	1.0
restaurant	1.0	0.055555556

Tablica 23: Precision i Recall dla własnych tekstów

Multi-Class Pecision: 0.575  
Uogólniona miara Ngramów

Label	Precision	Recall
movie	0.72727275	0.8888889
restaurant	0.8888889	0.72727275

Tablica 24: Precision i Recall dla własnych tekstów i uogólnionej miary NGramów

Multi-Class Pecision: 0.8  
k = 8

Label	Precision	Recall
movie	0.5897436	1.0
restaurant	1.0	0.05882353

Tablica 25: Precision i Recall dla własnych tekstów i uogólnionej miary NGramów

Multi-Class Precision: 0.6

## 6. Dyskusja

Napisanie programu klasyfikującego uświadomiło nam, że w rozpoznawaniu danego tekstu nie liczą się jedynie znaczenia poszczególnych słów. Pozytywny wpływ na jakość klasyfikacji miało między innymi dodanie do ekstrakcji cech „punktowanie” słów znajdujących się bliżej początku artykułu. Właściwość ta jest związana z podstawowymi założeniami artykułu prasowego, i w tekstach opracowanych przez nas recenzji, które mają na celu w pierwszych słowach określić kontekst danego tekstu. Zdajemy sobie sprawę, że dla innego typu tekstu pisanego, takiego jak na przykład opowiadanie cecha ta niekoniecznie będzie obecna, nastąpi wtedy konieczność stworzenia nowego modelu ekstrakcji cech, do którego przyjęcia nasz program jest zdolny.

Zauważyliśmy, że uogólniona miara n-gramów pozwala na osiągnięcie lepszych wyników klasyfikacyjnych od trigramów. Dzieje się tak, ponieważ uogólniona miara n-gramów pozwala na wyższy stopień rozgraniczenia podobieństwa tekstów, poprzez uwzględnienie aspektów niebędących możliwymi do wyłapania w przypadku trigramów. Jedynym przeciwwskazaniem w użyciu uogólnionej miary n-gramów może być jej wyższa złożoność obliczeniowa.

Z trzech miar pomiaru odległości między wektorami, najlepsze rezultaty daje według naszych badań metryka Euklidesa, zaraz za nią jest metryka Czebyszewa, natomiast na końcu plasuje się metryka uliczna. Dystans Euklidesa najlepiej więc oddaje odległość pomiędzy wektorami w przestrzeni dla zastosowania algorytmu k najbliższych sąsiadów.

Algorytm TFIDF okazał się wolniejszy od alternatywnego rozwiązania w drugim sposobie ekstrakcji. Jest to spowodowane jego złożonością obliczeniową w porównaniu do usuwania słów ze stop listy i punktowaniu słów pojawiających się wcześniej. Osiągał on też mniejsze wartości. Jest on jednak w przeciwieństwie do stworzonej przez nas stop-listy uniwersalny.

Normalizacja wektorów cech okazała się niezwykle kluczowa ze względu na różną długość artykułów i recenzji znajdujących się w zbiorach danych. Początkowe próby działania programu bez uniezależnienia wartości na wektorze od długości tekstów dawały bardzo niskie rezultaty.

Rezultaty dla przygotowywanych przez nas tekstów były znacząco niższe niż dla tekstów zaczerpniętych z bazy Reutersa. Jest to zapewne spowodowane spójnym stylem i określoną formą tekstów Reutersa, podczas gdy przygotowane przez nas teksty znacząco się różniły pod względem stylistycznym jak i formalnym.

Program osiągnął średnią skuteczność na poziomie 90-95 procent dla tylko dwóch etykiet. Jest to przewidywany efekt. Skuteczność wzrastała nawet do

97 procent po zwiększeniu  $k$  z 3 do 5. Jest to wynik więcej niż satysfakcjonujący.

## 7. Wnioski

Stworzenie systemu ekstrakcji cech dla danego rodzaju bądź zbioru tekstów jest zadaniem o wiele trudniejszym niż przypuszczaliśmy i wymaga nie tylko wiedzy o słowach jakie mogą się znaleźć w danym tekście, ale i dogłębnej wiedzy o wybranym typie tekstu, jak w naszym przypadku artykule jak i w wybranym przez nas, podobnej jeśli chodzi o cechy recenzji.

Algorytm  $k$  najbliższych sąsiadów ma problem, w momencie, kiedy jedna z etykiet ma znacząco więcej przyporządkowanych do niej elementów. Ważne jest wtedy aby odpowiednio dobrać wartość  $k$  aby nie była zbyt wysoka. Należy też wtedy zadbać o to, aby do zbioru początkowo odkrytych etykiet dla elementów trafiły etykiety każdego rodzaju.

Uniwersalne metody zawsze będą mniej skuteczne niż metody skrojone dokładnie pod dany przypadek. Jest to uniwersalna prawda, która w informatyce odgrywa znaczącą rolę w porównaniu do innych dziedzin. Mogliśmy ją zaobserwować na przykładzie porównania algorytmu TFIDF z stop-listą i wybieraniem słów pojawiających się wcześniej.

## Literatura

- [1] David D. Lewis. *Feature Selection and Feature Extraction for Text Categorization*, University of Chicago,  
Dostępny w Internecie: <https://aclweb.org/anthology/H92-1041?fbclid=IwAR248ftiyFqXrFpi51IDLorT7Ngso369BPT0a0eSYE3QGG1gYD9TNfy58qc>
- [2] David Dolan Lewis. *Representation and learning in information retrieval*, University of Massachusetts,  
Dostępny w Internecie: <http://ciir.cs.umass.edu/pubfiles/UM-CS-1991-093.pdf>
- [3] David D. Lewis. *Data Extraction as Text Categorization : An Experiment With the MUC-3 Corpus*, University of Chicago,  
Dostępny w Internecie: <https://www.aclweb.org/anthology/M91-1035>
- [4] Marina Sokolova, Guy Lapalme. *A systematic analysis of performance measures for classification tasks*, Information Processing and Management no 45,  
Dostępny w internecie: [http://rali.iro.umontreal.ca/rali/sites/default/files/publis/SokolovaLapalme-JIPM09.pdf?fbclid=IwAR2M7\\_a4QxL\\_F4yCOB\\_Akp4ghkoUKrBnHT9xzCfuTcoVrLBe3lN3kIlPt00](http://rali.iro.umontreal.ca/rali/sites/default/files/publis/SokolovaLapalme-JIPM09.pdf?fbclid=IwAR2M7_a4QxL_F4yCOB_Akp4ghkoUKrBnHT9xzCfuTcoVrLBe3lN3kIlPt00)
- [5] Dokumentacja Stanford CoreNLP <https://stanfordnlp.github.io/CoreNLP>
- [6] Adam Niewiadomski. *Materiały, przykłady i ćwiczenia do przedmiotu Komputerowe Systemy Rozpoznawania*, 21 września 2009.